原版PT的MFVI推导

符号约定

d: `dim_z`

m: `dim_g`

n: `seq_len`

r: `ternary_rank`

势函数

$\phi_u(Z_i = a) = \exp(S_{w_i,a})$
$\phi_t(H_i = k, Z_i = a, Z_j = b) = \exp(T_{a,b})(H_i = j, \text{否则为}1)$
$\phi_b(Z_i = a, G_i = g) = \exp(B_{g,a})$

联合概率分布

给定序列w（坐标为$i \in 1 \sim n$）,给定各位置i的Z_i, G_i, H_i，此取值概率为：$P(Z, H, G|w) = \text{Normalization}\{\Pi_{i=1}^n \phi_u(Z_i) * \Pi_{i=1}^n \phi_b(Z_i, G_i) * \Pi_{c=1}^h \Pi_{i=1}^n \Pi_{j=1}^n \phi_t(H_i^{(c)}, Z_i, Z_j)\}$

MFVI

变分自由能函数：$F(Q) = E_Q[-\log P(Z, H, G|w)] - H(Q)$
$= -\sum_{i=1}^n (\sum_{a=1}^d Q_i(Z_i = a) S_{w_i,a})$
$-\sum_{c=1}^C \sum_{i=1}^n (\sum_{j \neq i} \sum_{a=1}^d \sum_{b=1}^d Q_{ic}(H_i = j) Q_i(Z_i = a) Q_j(Z_j = b) T_{a,b}^{(c)})$
$-\sum_{i=1}^n (\sum_{a=1}^d \sum_{g=1}^m Q_i(Z_i = a) Q_i^G(G_i = g) B_{g,a})$
$-H(Q)$

MFVI: 求$Q_i(a)$分布使得$F(Q)$取得最小值，且$\sum_a Q_i(a) = 1$。以此构建Lagrange函数，使其对$Q_i(a)$偏导为0，解出一次迭代后的$Q_i(a)$。

Lagrange:$L = F(Q) + \lambda(\sum_z Q_i(a) - 1)$
偏导为0$\Rightarrow \nabla E - \ln Q_i(a) - 1 + \lambda = 0$ (其中∇E为$E_Q[-\log P(Z, H, G|w)]$对$Q_i(a)$的偏导，$\ln Q_i(a) + 1$为$H(Q)$对$Q_i(a)$的偏导)

$\nabla E_{Q_{ic}(j)}$的求解与$Q_{ic}(j)$的更新：

$\frac{\partial E}{\partial Q_{ic}(j)} = -\sum_a \sum_b Q_i(a)Q_j(b)T_{a,b}(c)$
$= -\sum_a \sum_b Q_i(a)Q_j(b)(\sum_l U_{a,l}V_{b,l})$
$= -\sum_l (\sum_a Q_i(a)U_{a,l})(\sum_b Q_j(b)V_{b,l})$
令$\sum_a Q_i(a)U_{a,l} = q_{i,l}, \sum_b Q_j(b)V_{b,l} = k_{j,l}$
则$\nabla E_{Q_{ic}(j)} = -\sum_{l=1}^{r} q_{i,l}k_{j,l} = -(\vec{q_i}\vec{k_j^T})$

由$Q \propto \exp(-\nabla E)$得：$Q_{ic}(j) \propto \exp(\vec{q_i}\vec{k_j^T})$

$\nabla E_{Q_i(a)}$的求解与$Q_i(a)$的更新：

对F,只考虑含$Q_i(a)$的项：
$F_i(Q) = -Q_i(a)S_{w_i,a}$
$-\sum_c \sum_{j\neq i} Q_{ic}(j) \sum_b Q_i(a)Q_j(b)T_{ab}^{(c)}$
$-\sum_c \sum_{k\neq i} Q_{kc}(i) \sum_b Q_k(b)Q_i(a)T_{ba}^{(c)}$
$-\sum_g Q_i(a)Q_i^G(g)B_{g,a}$

$\nabla_{unary} = -S_{w_i,a}$
$\nabla_{child} = -\sum_c \sum_{j\neq i} Q_{ic}(j)(\sum_b Q_j(b)T_{a,b}^{(c)})$
$\nabla_{head} = -\sum_c \sum_{k\neq i} Q_{kc}(i)(\sum_b Q_k(b)T_{b,a}^{(c)})$
$\nabla_{binary} = -\sum_g Q_i^G(g)G_{g,a}$
$\therefore \nabla E = \nabla_{unary} + \nabla_{child} + \nabla_{head} + \nabla_{binary}$
代入Lagrange函数，令其偏导为0$\Rightarrow \ln Q_i(a) = -\nabla E + 1 - \lambda$
$\Rightarrow Q_i(a) \propto \exp(-\nabla E)$
$\Rightarrow Q_i(a) = \mathrm{Softmax}(-\nabla E)$

即：$\mathrm{Logits}_i(a) = -\nabla E$
$= S_{w_i,a} + \sum_c \sum_{j\neq i} Q_{ic}(j)(\sum_b Q_j(b)T_{a,b}^{(c)}) + \sum_c \sum_{k\neq i} Q_{kc}(i)(\sum_b Q_k(b)T_{b,a}^{(c)}) +$
$\sum_g Q_i^G(g)B_{g,a}$

考虑T矩阵分解：

$\sum_{j\neq i} Q_{ic}(j)(\sum_b Q_j(b)T_{a,b}^{(c)}) = \sum_j \mathrm{Attn}_{ij}(Q_jT) = \sum_j \mathrm{Attn}_{ij}(Q_jV)U^T$
$\sum_{k\neq i} Q_{kc}(i)(\sum_b Q_k(b)T_{b,a}^{(c)}) = \sum_k \mathrm{Attn}_{ki}(Q_kT) = \sum_k \mathrm{Attn}_{ki}(Q_kU)V^T$

相应代码： `qz_new = Softmax(Input_S + (Attn_Child + Attn_Head) + FFN_Output)`

muP版 PT的MFVI推导

势函数 (muP Scaled)

$\tau = \frac{d}{r}$，为Q_i分布的温度参数。Q_{ic}分布的温度参数仍为1。后续进行推导解释。
$\phi_u(Z_i = a) = \exp(\tau S_{w_i,a})$
$\phi_t(H_i = k, Z_i = a, Z_j = b) = \exp(\tau d T_{a,b})(H_i = j, \text{否则为}1)$
$\phi_b(Z_i = a, G_i = g) = \exp(\tau m B_{g,a})$

联合概率分布

给定序列w（坐标为$i \in 1 \sim n$）,给定各位置i的Z_i, G_i, H_i，此取值概率为：$P(Z, H, G|w) = \text{Normalization}\{\Pi_{i=1}^n \phi_u(Z_i) * \Pi_{i=1}^n \phi_b(Z_i, G_i) * \Pi_{c=1}^h \Pi_{i=1}^n \Pi_{j=1}^n \phi_t(H_i^{(c)}, Z_i, Z_j)\}$

MFVI

变分自由能函数：$F(Q) = E_Q[-\log P(Z, H, G|w)] - \tau H(Q)$(添加了系数$\tau$，后续进行推导)
$= -\sum_{i=1}^n (\sum_{a=1}^d Q_i(Z_i = a)\tau S_{w_i,a})$
$-\sum_{c=1}^C \sum_{i=1}^n (\sum_{j \neq i} \sum_{a=1}^d \sum_{b=1}^d Q_{ic}(H_i = j) Q_i(Z_i = a) Q_j(Z_j = b)(\tau d T_{a,b}^{(c)}))$
$-\sum_{i=1}^n (\sum_{a=1}^d \sum_{g=1}^m Q_i(Z_i = a) Q_i^G(G_i = g)(\tau m B_{g,a}))$
$-\tau H(Q)$

MFVI: 求$Q_i(a)$分布使得$F(Q)$取得最小值，且$\sum_a Q_i(a) = 1$。以此构建Lagrange函数，使其对$Q_i(a)$偏导为0，解出一次迭代后的$Q_i(a)$。

Lagrange:$L = F(Q) + \lambda(\sum_z Q_i(a) - 1)$
偏导为0$\Rightarrow \nabla E - \tau(\ln Q_i(a) + 1) + \lambda = 0$ (其中∇E为$E_Q[-\log P(Z, H, G|w)]$对$Q_i(a)$的偏导，$\ln Q_i(a) + 1$为$H(Q)$对$Q_i(a)$的偏导)

$\nabla E_{Q_{ic}(j)}$的求解与$Q_{ic}(j)$的更新：

$\frac{\partial E}{\partial Q_{ic}(j)} = -\sum_a \sum_b Q_i(a) Q_j(b)(\tau d T_{a,b}(c))$
$= -\tau d \sum_a \sum_b Q_i(a) Q_j(b)(\sum_l U_{a,l} V_{b,l})$
$= -\tau d \sum_l (\sum_a Q_i(a) U_{a,l})(\sum_b Q_j(b) V_{b,l})$
令$\sum_a Q_i(a) U_{a,l} = q_{i,l}, \sum_b Q_j(b) V_{b,l} = k_{j,l}$
则$\nabla E_{Q_{ic}(j)} = -\tau d \sum_{l=1}^r q_{i,l} k_{j,l} = -(\frac{d^2}{r} \vec{q_i} \vec{k_j^T})$

由$Q \propto \exp(-\nabla E)$得：$Q_{ic}(j) \propto \exp(\frac{d^2}{r} \vec{q_i} \vec{k_j^T})$

$\nabla E_{Q_i(a)}$的求解与$Q_i(a)$的更新：

对F,只考虑含$Q_i(a)$的项：
$F_i(Q) = -Q_i(a)\tau S_{w_i,a}$
$-\sum_c \sum_{j\neq i} Q_{ic}(j) \sum_b Q_i(a)Q_j(b)(\tau dT_{ab}^{(c)})$
$-\sum_c \sum_{k\neq i} Q_{kc}(i) \sum_b Q_k(b)Q_i(a)(\tau dT_{ba}^{(c)})$
$-\sum_g Q_i(a)Q_i^G(g)(\tau mB_{g,a})$

$\nabla_{unary} = -\tau S_{w_i,a}$
$\nabla_{child} = -\sum_c \sum_{j\neq i} Q_{ic}(j)(\sum_b Q_j(b)\tau dT_{a,b}^{(c)})$
$\nabla_{head} = -\sum_c \sum_{k\neq i} Q_{kc}(i)(\sum_b Q_k(b)\tau dT_{b,a}^{(c)})$
$\nabla_{binary} = -\sum_g Q_i^G(g)(\tau mB_{g,a})$
$\therefore \nabla E = \nabla_{unary} + \nabla_{child} + \nabla_{head} + \nabla_{binary}$
代入Lagrange函数，令其偏导为0$\Rightarrow \ln Q_i(a) = -\frac{1}{\tau}\nabla E + 1 - \frac{1}{\tau}\lambda$
$\Rightarrow Q_i(a) \propto \exp(-\frac{1}{\tau}\nabla E)$
$\Rightarrow Q_i(a) = \mathrm{Softmax}(-\frac{1}{\tau}\nabla E)$

即：$\mathrm{Logits}_i(a) = -\frac{1}{\tau}\nabla E$
$= \frac{1}{\tau}[\tau S_{w_i,a} + \tau d\sum_c \sum_{j\neq i} Q_{ic}(j)(\sum_b Q_j(b)T_{a,b}^{(c)}) + \tau d\sum_c \sum_{k\neq i} Q_{kc}(i)(\sum_b Q_k(b)T_{b,a}^{(c)}) + \tau m\sum_g Q_i^G(g)B_{g,a}]$
$= S_{w_i,a} + d\sum_c \sum_{j\neq i} Q_{ic}(j)(\sum_b Q_j(b)T_{a,b}^{(c)}) + d\sum_c \sum_{k\neq i} Q_{kc}(i)(\sum_b Q_k(b)T_{b,a}^{(c)}) + m\sum_g Q_i^G(g)B_{g,a}$

考虑T矩阵分解：

$\sum_{j\neq i} Q_{ic}(j)(\sum_b Q_j(b)T_{a,b}^{(c)}) = \sum_j \mathrm{Attn}_{ij}(Q_jT) = \sum_j \mathrm{Attn}_{ij}(Q_jV)U^T$
$\sum_{k\neq i} Q_{kc}(i)(\sum_b Q_k(b)T_{b,a}^{(c)}) = \sum_k \mathrm{Attn}_{ki}(Q_kT) = \sum_k \mathrm{Attn}_{ki}(Q_kU)V^T$

代码实现的契合性检验

有关特殊缩放的代码：

```
class SquaredSoftmax(nn.Module):
    def __init__(self, dim=-1, eps=1e-6):
        super().__init__()
        self.dim = dim
        self.eps = eps

    def forward(self, hidden_states: torch.Tensor):
        input_dtype = hidden_states.dtype
        hidden_states = hidden_states.to(torch.float32)
        hidden_states = hidden_states.pow(2)
        # Energy Recovery: scale by dim
        hidden_states = F.normalize(hidden_states, p=1, dim=self.dim, eps=self.eps) * hidden_sta
        return hidden_states.to(input_dtype)


class AbsNormalization(nn.Module):
    def __init__(self, dim=-1, eps=1e-6):
        super().__init__()
        self.dim = dim
        self.eps = eps

    def forward(self, hidden_states: torch.Tensor):
        input_dtype = hidden_states.dtype
        hidden_states = hidden_states.to(torch.float32)
        hidden_states = F.relu(hidden_states)
        # Energy Recovery: scale by dim
        hidden_states = F.normalize(hidden_states, p=1, dim=self.dim, eps=self.eps) * hidden_sta
        return hidden_states.to(input_dtype)
```

即： `potential_function_z` 为 `square` , `potential_function_g` 为 `abs` ，归一化时增加了 `* hidden_states.shape[self.dim]`

原始代码中，涉及到归一化操作的变量为： `qz` ：相当于$Q_i(a)$； `qg` ：相当于$Q_i^G(g)$。原始代码中，经过归一化相当于： `qz` 与 `qg` 显式代表了概率分布。

修改后的代码中： `qz` 和 `qg` 分别乘上了d和m，即不再显示代表概率分布，而是代表概率分布乘宽度。

结合MFVI推导：

$\nabla E_{Q_{ic}(j)}$的求解与$Q_{ic}(j)$的更新：

$$\frac{\partial E}{\partial Q_{ic}(j)} = -\sum_a \sum_b Q_i(a)Q_j(b)(\frac{d^2}{r}T_{a,b}(c))$$
$$= -\frac{1}{r}\sum_a \sum_b (dQ_i(a))(dQ_j(b))(T_{a,b}(c))$$

$= -\frac{1}{r}\sum_l(\sum_a dQ_i(a)U_{a,l})(\sum_b dQ_j(b)V_{b,l})$
令 $\sum_a dQ_i(a)U_{a,l} = q_{i,l}, \sum_b dQ_j(b)V_{b,l} = k_{j,l}$
则 $\nabla E_{Q_{ic}(j)} = -\frac{1}{r}\sum_{l=1}^{r} q_{i,l}k_{j,l} = -(\frac{1}{r}\vec{q_i}\vec{k_j^T})$

此时 `qz` 即代表$dQ_i(a)$整体。原始代码中的 `Message_F` 即为$-\vec{q_i}\vec{k_j^T}$。为保持与MFVI推断的一致性，需将 `Message_F` 额外除以r（ternary_rank）。此时代码中 `Message_F` 即代表$-(\frac{1}{r}\vec{q_i}\vec{k_j^T})$，归一化后得$Q_ic(j)$，对应的变量为 `qh` 。

其余与原始MFVI推导一致。

$\nabla E_{Q_i(a)}$的求解与$Q_i(a)$的更新：

$\mathrm{Logits}_i(a) = -\frac{1}{\tau}\nabla E$
$= \frac{1}{\tau}[\tau S_{w_i,a} + \tau d\sum_c\sum_{j\neq i} Q_{ic}(j)(\sum_b Q_j(b)T_{a,b}^{(c)}) + \tau d\sum_c\sum_{k\neq i} Q_{kc}(i)(\sum_b Q_k(b)T_{b,a}^{(c)}) + \tau m\sum_g Q_i^G(g)B_{g,a}]$
$= \frac{1}{\tau}[\tau S_{w_i,a} + \tau\sum_c\sum_{j\neq i} Q_{ic}(j)(\sum_b dQ_j(b)T_{a,b}^{(c)}) + \tau\sum_c\sum_{k\neq i} Q_{kc}(i)(\sum_b dQ_k(b)T_{b,a}^{(c)}) + \tau\sum_g mQ_i^G(g)B_{g,a}]$
$= S_{w_i,a} + \sum_c\sum_{j\neq i} Q_{ic}(j)(\sum_b dQ_j(b)T_{a,b}^{(c)}) + \sum_c\sum_{k\neq i} Q_{kc}(i)(\sum_b dQ_k(b)T_{b,a}^{(c)}) + \sum_g mQ_i^G(g)B_{g,a}$

其中dQ_j,$dQ_k(b)$,$mQ_i^G(g)$仍对应代码中的 `qz` `qg` ，这两者仍然不再显示表示概率分布，但上式最终计算结果为概率分布。

Conclusion: 经过调整后，仍然能够符合MFVI的推导步骤。区别在于缩放因子被合入相关变量中。

代码总共进行了两处与原始PT不同的特殊缩放：
1.Normalization函数中全部乘 `self.dim[-1]` ，对应了 `qz` `qg` 意义的改变
2. `Message_F` 额外除以r，对应了凑齐$\nabla E_{Q_{ic}(j)}$的表达式。

Q_i温度参数τ合理性的推导（1）

在此推导第一种scaling方案： `num_channels` 随d线性缩放，r保持不变。

推导结论为：能量函数与熵函数在训练中后期的数量级都为$\Theta(d)$，二者保持了数量级的平衡。而在训练前期则熵函数数量级相对较大，有利于训练初期快速脱离均匀分布状态。

变分自由能函数：$F(Q) = E_Q[-\log P(Z,H,G|w)] - \tau H(Q)$(添加了系数$\tau$，后续进行推导)
$= -\sum_{i=1}^{n}(\sum_{a=1}^{d} Q_i(Z_i = a)\tau S_{w_i,a})$
$-\sum_{c=1}^{C}\sum_{i=1}^{n}(\sum_{j\neq i}\sum_{a=1}^{d}\sum_{b=1}^{d} Q_{ic}(H_i = j)Q_i(Z_i = a)Q_j(Z_j = b)(\tau d T_{a,b}^{(c)}))$
$-\sum_{i=1}^{n}(\sum_{a=1}^{d}\sum_{g=1}^{m} Q_i(Z_i = a)Q_i^G(G_i = g)(\tau m B_{g,a}))$
$-\tau H(Q)$

熵函数的数量级推导

$H(Q) = -\sum_{a=1}^{d} Q(a)\ln Q(a)$

训练初期的数量级(按均匀分布计)：$\sum_{a=1}^{d}\frac{1}{d}\ln\frac{1}{d} = \ln d$
$\tau H(Q) = \Theta(\frac{d}{r}\ln d) = \Theta(d\ln d)$

训练收敛期的数量级：
收敛期趋向于：有限K个标签占据绝大多数概率累积值，剩余标签概率极小。
$H(Q) = \Theta(\ln K) = \Theta(1)$
$\tau H(Q) = \Theta(d)$

能量函数一元势项的数量级推导

$E = -\sum_{a=1}^{d} Q_i(a)(\tau S_{w_i,a})$
$= -\frac{1}{r}\sum_{a=1}^{d} q_i^{code}(a)S_{w_i,a}$(此处$q_i^{code}(a)$即指代代码中的 `qz` ，代表$dQ_i(a)$)

训练初期的数量级(按均匀分布计)：
训练初期,S的d个求和单项视为互相独立，则S的方差为d个单项的方差直接相加：$Var(E) = dVar(q_i^{code}(a)S_{w_i,a})$
根据参数化方法，$S_{w_i,a}$数量级为$\Theta(1)$; $q_i^{code}(a) = dQ_i(a) = d\Theta(\frac{1}{d}) = \Theta(1)$
$Var(E) = d\Theta(1) = \Theta(d) \Rightarrow |E| = \Theta(\sqrt{d})$

训练收敛期的数量级：
训练收敛期时，q与S_{w_i}趋向对齐，即向量计算点积时，各对应项符号高度相关而非独立，所以视为同方向相加，无明显的正负抵消（在二元势部分进行了说明）。所以认为 $\sum_{a=1}^{d} q_i^{code}(a)S_{w_i,a}$的d个累加项$x_a$：$x_a = \Theta(1)\Theta(1) = \Theta(1)$,所以$\sum_{a=1}^{d} q_i^{code}(a)S_{w_i,a} = \Theta(d)$, 所以$E = \Theta(d)$

能量函数二元势项的数量级推导

$E = -\sum_i agQ_i(a)Q_i^G(g)(\tau m B_{g,a})$
$= -\sum_a\sum_g q^{code}(a)q^{G,code}(g)B_{g,a}$（由参数化方法，B与三元势的T相关矩阵数量级为$\Theta(\frac{1}{\sqrt{d}})$）

训练初期的数量级(按均匀分布计)：
$Var(E)=\sum_{a,g}Var(q^{code}(a)q^{G,code}(g)B_{g,a})=\sum_{a,g}(\Theta(1)\Theta(1)\Theta(\frac{1}{d}))=\Theta(d^2)\Theta(\frac{1}{d})=\Theta(d)$
$\Rightarrow |E|=\sqrt{d}$

训练收敛期的数量级：
$E=-\sum_a q^{code}(a)\sum_g q^{G,code}B_{g,a}$
$\sum_g q^{G,code}B_{g,a}$中，向量点积的各累计项符号高度相关（下面为说明），视为同方向相加，无正负抵消。
求$\sum_g q^{G,code}B_{g,a}$的数量级：
由参数化方案得：$B_{g,a}=B_{g,a}^{init}+B_{g,a}^{learn}$，其中$B_{g,a}^{init}=\Theta(\frac{1}{\sqrt{d}}),B_{g,a}^{learn}=\Theta(\frac{1}{d})$
$\sum_g q^{G,code}B_{g,a}=\sum_g q^{G,code}B_{g,a}^{init}+q^{G,code}B_{g,a}^{learn}$
第一项数量级的推导参照独立分布，解出方差为$\Theta(1)$，即数量级为$\Theta(1)$。
第二项中，由梯度计算可得：$\Delta B_{g,a}$正比于q，即：趋向于同q对齐。
所以第二项的数量级为：$\sum_g\Theta(1)\Theta(\frac{1}{d})=\Theta(1)$

所以$\sum_g q^{G,code}B_{g,a}$的总数量级为$\Theta(1)$
E的数量级为：$\sum_a\Theta(1)\Theta(1)=\Theta(d)$

能量函数三元势项的数量级推导

$E=-\sum_{c=1}^{C}\sum_i\sum_j Q_{ic}(j)(\sum_{a=1}^{d}\sum_{b=1}^{d}Q_i(a)Q_j(b)\tau dT_{a,b}^{(c)})$

单个channel能量：$E=-\sum_{i,j}Q_{ic}(j)(\sum_{a=1}^{d}\sum_{b=1}^{d}Q_i(a)Q_j(b)\tau dT_{a,b}^{(c)})=-\sum_{i,j}Q_ic(j)\sum_{a=1}^{d}\sum_{b=1}^{d}q_i^{code}(a)q_j^{code}(b)T_{a,b}$

训练初期的数量级：结果同一元、二元一样，过程略
训练收敛期的数量级：
$\sum_{a=1}^{d}\sum_{b=1}^{d}q_i^{code}(a)q_j^{code}(b)T_{a,b}=\sum_{l=1}^{r}\sum_{a=1}^{d}\sum_{b=1}^{d}(q_i^{code}U_{a,l})(V_{b,l}q_j^{code})=\sum_{l=1}^{r}(\sum_{a=1}^{d}q_i^{code}U_{a,l})(\sum_{b=1}^{d}q_j^{code}V_{b,l})$
根据梯度计算，$U_{a,l}$的梯度与q_i^{code}成正比，$V_{b,l}$的梯度与q_j^{code}成正比，对应了U,V更新量的对齐关系。
$U_{a,l}=U_{a,l}^{init}+U_{a,l}^{learn}$,$V_{b,l}=V_{b,l}^{init}+V_{b,l}^{learn}$，后者有对齐关系，前者为完全随机。

$(\sum_{a=1}^{d}q_i^{code}U_{a,l})(\sum_{b=1}^{d}q_j^{code}V_{b,l})=[(\sum_{a=1}^{d}q_i^{code}U_{a,l}^{init})+(\sum_{a=1}^{d}q_i^{code}U_{a,l}^{learn})][(\sum_{b=1}^{d}q_j^{code}V_{b,l}^{init})+(\sum_{b=1}^{d}q_j^{code}V_{b,l}^{learn})]$
共有4项：1个init相乘项，2个交叉项，1个learn相乘项。
对于init相乘项，分析$\sum_{a=1}^{d}q_i^{code}U_{a,l}^{init}$方差可得数量级为$\Theta(1)$,$V$同理，所以相乘项数量级为$\Theta(1)$。
由于U^{init}与U^{learn}独立，且U^{learn}数量级为$\Theta(\frac{1}{d})<\Theta(\frac{1}{\sqrt{d}})$，故交叉相乘项数量级小于init相乘项，省

略。
对于learn相乘项：$\sum_{a=1}^{d} q_i^{code} U_{a,l}^{learn} = \sum_{a=1}^{d} \Theta(1)\Theta(\frac{1}{d}) = \Theta(1)$,故相乘项数量级为$\Theta(1)$
综上，$\sum_{a=1}^{d}\sum_{b=1}^{d} q_i^{code}(a) q_j^{code}(b) T_{a,b}$数量级为$\Theta(1)$

所以 $-\sum_{i,j} Q_{ic}(j) \sum_{a=1}^{d}\sum_{b=1}^{d} q_i^{code}(a) q_j^{code}(b) T_{a,b} = -\sum_{i,j} Q_{ic}(j)\Theta(1) = \Theta(1)$(等于取平均)

考虑多个channel合并：
`Message_F` 在代码中额外除以 `ternary_rank` =$\Theta(\frac{d}{C})$进行额外修正：单个channel能量最终数量级为$\Theta(\frac{C}{d})\Theta(1) = \Theta(\frac{C}{d})$
所有channel能量累加：$\Theta(\frac{C^2}{d}) = \Theta(d)$ (注：$\Theta(C) = \Theta(d)$)

Conclusion

训练初期：能量函数每项的数量级都为$\sqrt{d}$，总数量级为$\sqrt{d}$；熵函数数量级为$d\ln d$，大于能量函数数量级。即：训练初期的效果更偏向熵函数的降低
训练中后期：能量函数每项的数量级都为d，总数量级为d；熵函数数量级为d，二者相等。即：在τ的当前取值下，随d变化，二者不会出现明显的大小失衡，使得分布与分布的熵都能维持在较为健康的状态直至训练收敛。而原先$\tau = 1$的情况下则无法满足二者的均衡。

Q_i温度参数 τ 合理性推导（2）

在此推导第二种 scaling 方案： `num_channels` (C) 保持不变（即 $\Theta(1)$），`ternary_rank` (r) 随 d 线性缩放（即 $r = \Theta(d)$）。

前置条件

根据定义 $\tau = \frac{d}{r}$。由于在此方案中 $r \propto d$，故温度系数 τ 的数量级为：

$$\tau = \Theta\left(\frac{d}{d}\right) = \Theta(1)$$

推导结论

能量函数与熵函数在训练收敛期的数量级都为 $\Theta(1)$，二者保持了数量级的平衡。而在训练初期，熵函数数量级为 $\Theta(\ln d)$，相对于能量函数（接近 0）较大，有利于训练初期快速脱离均匀分布状态。

熵函数的数量级推导

$H(Q) = -\sum_{a=1}^{d} Q(a) \ln Q(a)$

训练初期的数量级（按均匀分布计）：

$H(Q) = \sum_{a=1}^{d} \frac{1}{d} \ln d = \ln d$

结合 $\tau = \Theta(1)$：

$\tau H(Q) = \Theta(1) \cdot \ln d = \Theta(\ln d)$

训练收敛期的数量级：

收敛期趋向于有限 K 个标签占据绝大多数概率累积值（置信分布）。

$H(Q) = \Theta(\ln K) = \Theta(1)$

$\tau H(Q) = \Theta(1) \cdot \Theta(1) = \Theta(1)$

能量函数一元势项的数量级推导

$E = -\sum_{a=1}^{d} Q_i(a)(\tau S_{w_i,a}) = -\frac{\tau}{d} \sum_{a=1}^{d} q_i^{code}(a) S_{w_i,a}$

训练初期的数量级（按均匀分布计）：

求和项 $\sum qS$ 视为 d 个独立变量的随机游走。

$\mathrm{Var}(\mathrm{Sum}) \sim d \cdot \mathrm{Var}(q \cdot S) = \Theta(d) \Rightarrow |\mathrm{Sum}| = \Theta(\sqrt{d})$

$E = \frac{\Theta(1)}{d} \cdot \Theta(\sqrt{d}) = \Theta\left(\frac{1}{\sqrt{d}}\right) \approx 0$

训练收敛期的数量级：

q 与 S 趋向对齐，视为同方向相加（相干叠加）。

$\sum_{a=1}^{d} q_i^{code}(a) S_{w_i,a} = \sum_{a=1}^{d} \Theta(1)\Theta(1) = \Theta(d)$

$E = \frac{\tau}{d} \cdot \Theta(d) = \frac{\Theta(1)}{d} \cdot \Theta(d) = \Theta(1)$

能量函数二元势项的数量级推导

$E = -\sum_a \sum_g Q_i(a) Q_i^G(g)(\tau r B_{g,a})$
$-\frac{\tau}{d} \sum_a q^{code}(a) \sum_g q^{G,code}(g) B_{g,a}$

训练初期的数量级：

同理，随机游走导致总和为 $\Theta(\sqrt{d})$ 量级，被分母 d 抑制。

$$E = \Theta\left(\frac{1}{\sqrt{d}}\right) \approx 0$$

训练收敛期的数量级：

对于内部求和 $\sum_g q^{G,code} B_{g,a}$：由 μP 参数化，$B = B^{init} + B^{learn}$。

1. **Init 部分**（$\frac{1}{\sqrt{d}}$）：随机游走 $\to \Theta(1)$。
2. **Learn 部分**（$\frac{1}{d}$）：对齐叠加 $\sum_g \Theta(1)\Theta(\frac{1}{d}) = \Theta(1)$。故内部求和整体为 $\Theta(1)$。

对于外部求和 $\sum_a$：

$$\sum_a q^{code}(a) \cdot |\text{Inner Sum}| \sim \Theta(1) \cdot \Theta(d) = \Theta(d)$$

代入总公式：

$$E = \frac{\tau}{d} \cdot \Theta(d) = \frac{\Theta(1)}{d} \cdot \Theta(d) = \Theta(1)$$

能量函数三元势项的数量级推导

$$E = -\sum_{c=1}^{C} \sum_{i,j} Q_{ic}(j) \left(\sum_{a,b} Q_i(a) Q_j(b) \tau r T_{a,b}^{(c)} \right)$$

在代码中，这对应于 `logits` 计算并加权。单个 Channel 的能量项（Logits 部分）：

$$\text{Logits} = \frac{\sum_{a,b} q_i^{code} q_j^{code} T_{a,b}}{\text{ternary_rank}}$$

> （注：这里 $r \cdot d$ 系数被吸收到 logits 的定义与 Q 的归一化中，最终表现为上述形式）

核心分析：Raw Sum $\sum qqT$ 的数量级

在此方案中，Rank $r \propto d$，即 $r = \Theta(d)$。$T_{a,b} = \sum_{l=1}^{r} U_{a,l} V_{b,l}$。

训练收敛期的数量级：

1. T 矩阵的元素量级：只看对齐的 Learn 部分（主导能量）：$U^{\text{learn}}, V^{\text{learn}} \sim \Theta(\frac{1}{d})$

$$T_{a,b}^{\text{learn}} = \sum_{l=1}^{r} U_{a,l} V_{b,l} \sim r \cdot \frac{1}{d} \cdot \frac{1}{d} = \Theta(d) \cdot \frac{1}{d^2} = \Theta\left(\frac{1}{d}\right)$$

2. Raw Sum 的求和：

$$\sum_{a=1}^{d} \sum_{b=1}^{d} q(a) q(b) T_{a,b} \sim d^2 \cdot \Theta(1) \cdot \Theta(1) \cdot \Theta\left(\frac{1}{d}\right) = \Theta(d)$$

> （注：这里 d^2 个项相干叠加）

归一化后的 Logits 数量级：

$\text{Logits} = \frac{\text{Raw Sum}}{\text{ternary rank}} = \frac{\Theta(d)}{\Theta(d)} = \Theta(1)$

总能量：

$E = -\sum_{c=1}^{C} \sum_{j} Q_{ic}(j) \cdot \text{Logits}$

由于 C 保持不变（$\Theta(1)$），且 $\sum Q_{ic} = 1$：

$E = C \cdot \Theta(1) = \Theta(1)$

Conclusion

训练初期：

- **熵函数**：$\Theta(\ln d)$
- **能量函数**：$\Theta\left(\frac{1}{\sqrt{d}}\right)$（接近 0）
- **结论**：熵函数占主导地位（$\ln d \gg 0$），推动分布接近均匀分布。

训练中后期：

- **熵函数**：$\Theta(1)$
- **能量函数**：$\Theta(1)$