1. BERT Baseline

训练4个或5个（Large可能暂时不做）不同大小的bert模型作为参考。

模型名称	层数	隐藏层维度	注意力头数	FFN 中间层维度	参数量
BERT-Tiny	2	128	2	512	4.4M
BERT-Mini	4	256	4	1024	11.3M
BERT-Medium	8	512	8	2048	42.0M
BERT-Base	12	768	12	3072	110M
BERT-Large	24	1024	16	4096	340M

2. PT小模型调参

在 `dim_z=256` ， `ternary rank=64` ， `num channels=10` 的小模型上调参。

待调参数：

- binary factor scaling
- ternary factor scaling
- classifier amplifier
- regularize_z
- regularize_g
- regularize_h
- learning rate

固定参数：

- dim_g/dim_z=4
- num_iteration=6
- potential func z=square
- potential func g=abs

3. num channels缩放

尝试dim_z=256（已在调参阶段训练完毕） 512 1024 1536 2560的模型，且ternary rank不变，num channels随dim_z线性缩放

- 512
  - rank=64
  - channel=20
- 1024
  - rank=64
  - channel=40
- 1536
  - rank=64
  - channel=60
- 2560
  - rank=64
  - channel=100

4. ternary rank缩放

尝试dim_z=256（已在调参阶段训练完毕） 512 1024 1536 2560的模型，且num channels不变，ternary rank随dim_z线性缩放

- 512
  - rank=128
  - channel=10
- 1024
  - rank=256
  - channel=10
- 1536
  - rank=384
  - channel=10
- 2560
  - rank=640
  - channel=10

5. AdaLN

一定程度上实现各层的解绑定。

算法介绍：

参数:

- `Shared Weights`：W_u, W_v, W_{topic} (所有层共享)
- `AdaLN Params`：$\Gamma \in \mathbb{R}^{L\times N}, \mathrm{B} \in \mathbb{R}^{L\times N}$ (L为迭代次数, N为dim_z)

1. 初始化 $qz_0 = \mathrm{unary_potentials}$
2. 循环 $t = 0 \to L-1$:
   - **提取当前层的调制参数**:
     $\gamma_t = \Gamma[t], \beta_t = \mathrm{B}[t]$。即：每层（每个迭代步）拥有独立的$\gamma$和$\beta$
   - **归一化 (保持原逻辑 + Energy Recovery)**:
     $z_{norm} = \mathrm{Norm}(qz_t) \times \mathrm{dim_z}$
   - **[唯一修改步骤] AdaLN 调制**:
     $z_{mod} = z_{norm} \cdot (1+\gamma_t) + \beta_t$
   - **计算功能流 (使用调制后的 z_{mod})**:
     $m_1 = \mathrm{HeadSelection}(z_{mod}, W_u, W_v)$
     $m_2 = \mathrm{TopicModeling}(z_{mod}, W_{topic})$
   - **状态更新 (Structural Update)**:
     $qz_{t+1} = (m_1 + m_2 + \mathrm{unary})/\mathrm{regularize_z}$
     $qz_{t+1} = \mathrm{Damp}(qz_{t+1}, qz_t)$
3. 输出 qz_L

实验方案：

超参数不变。先试验dim_z=256时与不使用相比的效果。若有效，则可尝试该方法与num channels缩放、ternary rank缩放叠加作用的效果。